

大型语言模型服务的高效内存管理与分页注意力

权宇硕^{1,*} 李卓涵^{1,*} 庄思源¹ 盛颖^{1,2} 郑连敏¹ 余浩³ 约瑟夫·E·冈萨雷斯¹ 张浩⁴ 伊昂·斯托伊卡¹
加州大学伯克利分校² 斯坦福大学³ 独立研究员⁴ 加州大学圣地亚哥分校

摘要

高吞吐量服务大型语言模型（LLMs）需要同时批处理足够多的请求。然而，现有系统面临挑战，因为每个请求的键值缓存（KV缓存）内存巨大，并且动态增长和缩小。当管理不当时，这种内存可能因碎片化和冗余复制而显著浪费，从而限制批处理大小。为了解决这个问题，我们提出了PagedAttention，这是一种受经典虚拟内存和操作系统中的分页技术启发的注意力算法。在此基础上，我们构建了vLLM，一个LLM服务系统，能够实现（1）KV缓存内存的近零浪费和（2）在请求内外灵活共享KV缓存，以进一步减少内存使用。我们的评估显示，vLLM在与最先进的系统（如FasterTransformer和Orca）相比时，在相同延迟水平下提高了流行LLMs的吞吐量2-4x。随着序列更长、模型更大和解码算法更复杂，改进更加明显。vLLM的源代码可在<https://github.com/vllm-project/vllm>公开获取。

1 引言

大型语言模型（LLMs）如GPT [5, 37] 和PaLM [9] 的出现使得新的应用程序得以实现，例如编程助手 [6, 18] 和通用聊天机器人 [19, 35]，这些应用程序开始深刻影响我们的工作和日常生活。许多云公司 [34, 44] 正在竞相提供这些作为托管服务的应用程序。然而，运行这些应用程序的成本非常高，需要大量的硬件加速器，如GPU。根据最近的估计，处理一个LLM请求的成本可能是传统关键词查询的10x倍 [43]。鉴于这些高成本，提高吞吐量——从而降低

Permission to make digital or hard copies of part or all of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for third-party components of this work must be honored. For all other uses, contact the owner/author(s).

SOSP '23, October 23–26, 2023, Koblenz, Germany

© 2023 Copyright held by the owner/author(s).

ACM ISBN 979-8-4007-0229-7/23/10.

<https://doi.org/10.1145/3600006.3613165>

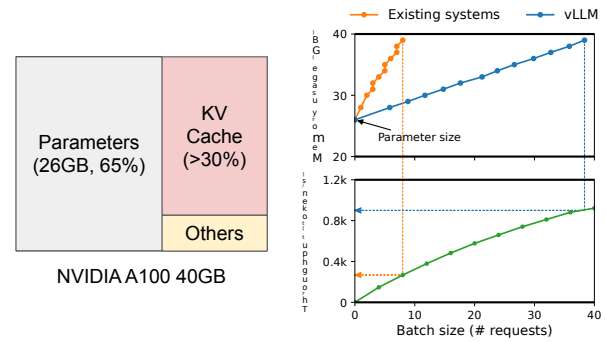


图1. 左侧：在NVIDIA A100上为具有13B参数的LLM提供服务时的内存布局。参数（灰色）在整个服务过程中持续存在于GPU内存中。KV缓存的内存（红色）根据每个服务请求进行（重新）分配。少量内存（黄色）用于瞬时激活。右侧：vLLM平滑了现有系统中KV缓存内存的快速增长曲线[31, 60]，显著提高了服务吞吐量。

LLM服务系统的每个请求成本变得越来越重要。

在大型语言模型的核心是一个自回归的Transformer模型[53]。该模型基于输入（提示）和迄今为止生成的输出令牌的前一个序列，逐个生成单词（令牌）。对于每个请求，这一昂贵的过程会重复，直到模型输出一个终止令牌。这个顺序生成过程使得工作负载受限于内存，未充分利用GPU的计算能力，并限制了服务吞吐量。

通过将多个请求批处理在一起，可以提高吞吐量。然而，为了在一个批次中处理许多请求，每个请求的内存空间应有效管理。例如，图1（左）展示了在具有40GB RAM的NVIDIA A100 GPU上，13B参数LLM的内存分配。大约65%的内存分配给模型权重，这在服务期间保持静态。接近30%的内存用于存储请求的动态状态。对于Transformers，这些状态由与注意力机制相关的键和值张量组成，通常称为KV缓存[41]，它们表示从早期标记到生成新输出标记的上下文。剩下的小部分

*Equal contribution.




图2. 在§6.2中的实验中，不同LLM服务系统的平均内存浪费百分比。

用于其他数据的内存百分比，包括激活 - 在评估LLM时创建的短暂张量。由于模型权重是恒定的，而激活仅占用GPU内存的一小部分，因此KV缓存的管理方式对于确定最大批量大小至关重要。当管理不当时，KV缓存内存可能会显著限制批量大小，从而影响LLM的吞吐量，如图1（右）所示。

在本文中，我们观察到现有的 LLM 服务系统 [31, 60] 在有效管理 KV 缓存内存方面存在不足。这主要是因为它们将请求的 KV 缓存存储在连续的内存空间中，而大多数深度学习框架 [33, 39] 要求张量存储在连续的内存中。然而，与传统深度学习工作负载中的张量不同，KV 缓存具有独特的特性：它随着模型生成新令牌而动态增长和缩小，其生命周期和长度是事先未知的。这些特性使得现有系统的方法在两个方面显著低效：

首先，现有系统 [31, 60] 遭受内部和外部内存碎片化的问题。为了在连续空间中存储请求的 KV 缓存，它们预先分配一个与请求最大长度（例如，2048 个标记）相等的连续内存块。这可能导致严重的内部碎片化，因为请求的实际长度可能远短于其最大长度（例如，图 11）。此外，即使实际长度是事先已知的，预分配仍然效率低下：由于在请求的生命周期内整个内存块都被保留，其他较短的请求无法利用当前未使用的内存块的任何部分。此外，外部内存碎片化也可能很严重，因为预分配的大小对于每个请求可能不同。实际上，我们在图 2 中的分析结果显示，现有系统中只有 20.4% - 38.2% 的 KV 缓存内存用于存储实际的标记状态。

其次，现有系统无法利用内存共享的机会。LLM 服务通常使用先进的

解码算法，例如并行采样和束搜索，能够为每个请求生成多个输出。在这些情况下，请求由多个序列组成，这些序列可以部分共享它们的KV缓存。然而，在现有系统中，内存共享是不可能的，因为序列的KV缓存存储在不同的连续空间中。

为了应对上述限制，我们提出了PagedAttention，这是一种受操作系统（OS）对内存碎片和共享解决方案启发的注意力算法：带分页的虚拟内存。PagedAttention将请求的KV缓存划分为块，每个块可以包含固定数量的令牌的注意力键和值。在PagedAttention中，KV缓存的块不一定存储在连续的空间中。因此，我们可以像操作系统的虚拟内存一样以更灵活的方式管理KV缓存：可以将块视为页面，将令牌视为字节，将请求视为进程。这种设计通过使用相对较小的块并按需分配它们来缓解内部碎片。此外，它消除了外部碎片，因为所有块的大小相同。最后，它使得在与同一请求相关的不同序列之间，甚至在不同请求之间以块的粒度进行内存共享成为可能。

在这项工作中，我们构建了 vLLM，这是一个基于 PagedAttention 的高吞吐量分布式 LLM 服务引擎，能够实现 KV 缓存内存的近乎零浪费。vLLM 使用与 PagedAttention 共同设计的块级内存管理和抢占式请求调度。vLLM 支持多种流行的 LLM，如 GPT [5]、OPT [62] 和 LLaMA [52]，包括超出单个 GPU 内存容量的模型。我们对各种模型和工作负载的评估表明，与最先进的系统 [31, 60] 相比，vLLM 提高了 LLM 服务的吞吐量 2-4x，而且完全不影响模型的准确性。随着序列变长、模型变大和解码算法变复杂，改进效果更加明显 (§4.3)。总之，我们做出了以下贡献：

- 我们识别了在服务大型语言模型（LLMs）时内存分配的挑战，并量化了它们对服务性能的影响。
- 我们提出了PagedAttention，这是一种在非连续分页内存中操作KV缓存的注意力算法，灵感来源于操作系统中的虚拟内存和分页。
- 我们设计并实现了 vLLM，一个基于 PagedAttention 构建的分布式 LLM 服务引擎。
- 我们在各种场景中评估 vLLM，并证明它在性能上大大超过了之前的最先进解决方案，如 FasterTransformer [31] 和 Orca [60]。

2 背景

在本节中，我们描述了典型大型语言模型（LLMs）的生成和服务程序，以及在LLM服务中使用的迭代级调度。

2.1 基于变换器的大型语言模型

语言建模的任务是对一系列标记 (x_1, \dots, x_n) 的概率进行建模。由于语言具有自然的顺序，因此通常将整个序列的联合概率分解为条件概率的乘积（即自回归分解 [3]）：

$$P(x) = P(x_1) \cdot P(x_2 | x_1) \cdots P(x_n | x_1, \dots, x_{n-1}). \quad (1)$$

变压器[53]已成为大规模建模上述概率的事实标准架构。基于变压器的语言模型中最重要的组成部分是其自注意力层。对于输入的隐藏状态序列 $(x_1, \dots, x_n) \in \mathbb{R}^{n \times d}$ ，自注意力层首先对每个位置 i 应用线性变换，以获取查询、键和值向量：

$$q_i = W_q x_i, \quad k_i = W_k x_i, \quad v_i = W_v x_i. \quad (2)$$

然后，自注意力层通过将每个位置的查询向量与之前的所有键向量相乘来计算注意力分数 a_{ij} ，并将输出 o_i 计算为值向量的加权平均：

$$a_{ij} = \frac{\exp(q_i^\top k_j / \sqrt{d}) \exp(q_i^\top k_t / \sqrt{d})}{\sum_{j=1}^i \exp(q_i^\top k_j / \sqrt{d})}, \quad o_i = \sum_{j=1}^i a_{ij} v_j. \quad (3)$$

除了公式4中的计算，Transformer模型中的所有其他组件，包括嵌入层、前馈层、层归一化[2]、残差连接[2]、输出logit计算，以及公式2中的查询、键和值转换，都是以 $y_i = f(x_i)$ 的形式独立地逐位置应用的。

2.2 LLM 服务与自回归生成

一旦训练完成，LLM 通常作为条件生成服务（例如，完成 API [34] 或聊天机器人 [19, 35]）进行部署。对 LLM 服务的请求提供了一系列输入提示标记 (x_1, \dots, x_n) ，LLM 服务根据公式 1 生成一系列输出标记 $(x_{n+1}, \dots, x_{n+T})$ 。我们将提示和输出列表的连接称为序列。

由于公式1中的分解，LLM只能逐个采样和生成新标记，每个新标记的生成过程依赖于该序列中所有先前的标记，特别是它们的键和值向量。在这个顺序生成过程中，现有标记的键和值向量通常会被缓存以生成未来的标记，这被称为KV缓存。请注意，一个标记的KV缓存依赖于它所有的先前标记。这意味着在序列中出现不同位置的相同标记的KV缓存将是不同的。

给定一个请求提示，LLM 服务中的生成计算可以分解为两个阶段：

提示阶段将整个用户提示 (x_1, \dots, x_n) 作为输入，并计算第一个新标记 $P(x_{n+1} | x_1, \dots, x_n)$ 的概率。在此过程中，还生成键向量 k_1, \dots, k_n 和值向量 v_1, \dots, v_n 。由于提示标记 x_1, \dots, x_n 都是已知的，因此提示阶段的计算可以使用矩阵-矩阵乘法操作进行并行化。因此，这个阶段可以有效利用 GPU 中固有的并行性。

自回归生成阶段顺序生成剩余的新标记。在迭代 t 中，模型将一个标记 x_{n+t} 作为输入，并使用键向量 k_1, \dots, k_{n+t} 和值向量 v_1, \dots, v_{n+t} 计算概率 $P(x_{n+t+1} | x_1, \dots, x_{n+t})$ 。请注意，位置 1 到 $n+t-1$ 的键和值向量在之前的迭代中被缓存，只有新的键和值向量 k_{n+t} 和 v_{n+t} 在此迭代中计算。此阶段在序列达到最大长度（由用户指定或由 LLM 限制）或发出序列结束标记（<eos>）时完成。由于数据依赖性，不同迭代的计算无法并行化，通常使用矩阵-向量乘法，这效率较低。因此，此阶段严重低估了 GPU 计算的利用率，并变得受限于内存，负责单个请求大部分延迟。

2.3 LLMs 的批处理技术

在为大型语言模型（LLMs）提供服务时，通过批量处理多个请求可以提高计算利用率。由于请求共享相同的模型权重，因此在一个批次中的请求之间移动权重的开销被摊销，并且当批量大小足够大时，这种开销可以被计算开销所压倒。然而，将请求批量处理到LLM服务并非易事，原因有二。首先，请求可能在不同时间到达。一种简单的批量策略要么让较早的请求等待较晚的请求，要么延迟即将到来的请求直到较早的请求完成，这会导致显著的排队延迟。其次，请求的输入和输出长度可能差异很大（图11）。一种简单的批量处理技术会对请求的输入和输出进行填充，以使它们的长度相等，这会浪费GPU计算和内存。

为了解决这个问题，提出了细粒度批处理机制，例如细胞批处理 [16] 和迭代级调度 [60]。与在请求级别工作的传统方法不同，这些技术在迭代级别上操作。在每次迭代后，已完成的请求会从批处理中移除，并添加新的请求。因此，新的请求可以在等待一个迭代后进行处理，而不必等待整个批次完成。此外，借助特殊的 GPU 内核，这些技术消除了对输入和输出进行填充的需求。通过减少排队延迟和填充带来的低效，细粒度批处理机制显著提高了 LLM 服务的吞吐量。

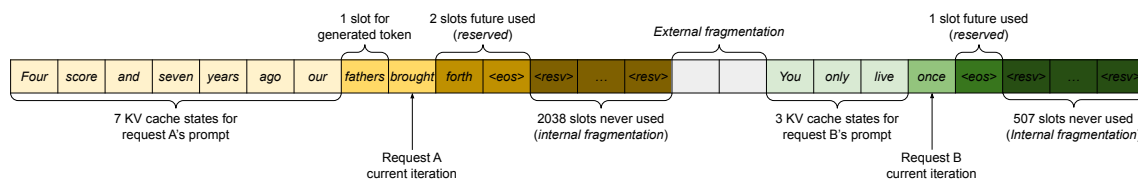


图3. 现有系统中的KV缓存内存管理。存在三种类型的内存浪费——保留、内部碎片和外部碎片——这些浪费阻止了其他请求适应内存。每个内存槽中的令牌代表其KV缓存。请注意，相同的令牌在不同位置时可以具有不同的KV缓存。

大型语言模型服务中的 3 个内存挑战

尽管细粒度批处理减少了计算浪费，并使请求能够以更灵活的方式进行批处理，但可以一起批处理的请求数量仍然受到GPU内存容量的限制，特别是分配用于存储KV缓存的空间。换句话说，服务系统的吞吐量受内存限制。克服这种内存限制需要解决内存管理中的以下挑战：

大型KV缓存。KV缓存的大小随着请求数量的增加而迅速增长。例如，对于13B参数的OPT模型[62]，单个令牌的KV缓存需要800 KB的空间，计算方式为 $2 \text{ (键和值向量)} \times 5120 \text{ (隐藏状态大小)} \times 40 \text{ (层数)} \times 2 \text{ (每个FP16的字节数)}$ 。由于OPT可以生成最多2048个令牌，因此存储一个请求的KV缓存所需的内存可能高达1.6 GB。并发GPU的内存容量在几十GB之间。即使所有可用内存都分配给KV缓存，也只能容纳几十个请求。此外，低效的内存管理可能进一步减少批处理大小，如图2所示。此外，考虑到当前的趋势，GPU的计算速度增长快于内存容量[17]。例如，从NVIDIA A100到H100，FLOPS增加了超过2倍，但GPU内存仍保持在80GB的最大值。因此，我们认为内存将成为一个日益重要的瓶颈。

复杂的解码算法。LLM服务提供了一系列解码算法供用户选择，每种算法对内存管理复杂性的影响各不相同。例如，当用户从单个输入提示请求多个随机样本时，这是程序建议中的典型用例[18]，提示部分的KV缓存在我们的实验中占总KV缓存内存的12% (§6.3)，可以共享以最小化内存使用。另一方面，自回归生成阶段的KV缓存由于样本结果的不同以及它们对上下文和位置的依赖，应保持不共享。KV缓存共享的程度取决于所采用的具体解码算法。在更复杂的算法如束搜索[49]中，不同的请求束可以共享更大部分（节省高达55%的内存，见

§6.3）它们的KV缓存，并且随着解码过程的推进，共享模式不断演变。

调度未知输入和输出长度。对LLM服务的请求在输入和输出长度上表现出变异性。这要求内存管理系统能够适应各种提示长度。此外，随着请求的输出长度在解码时增长，所需的KV缓存内存也会增加，可能会耗尽可用于处理传入请求或为现有提示进行持续生成的可用内存。系统需要做出调度决策，例如从GPU内存中删除或交换某些请求的KV缓存。

3.1 现有系统中的内存管理

由于当前深度学习框架中的大多数操作符 [33, 39] 需要张量存储在连续的内存中，以前的 LLM 服务系统 [31, 60] 也将一个请求的 KV 缓存存储为跨不同位置的连续张量。由于 LLM 的输出长度不可预测，它们根据请求的最大可能序列长度静态分配一块内存，而不考虑请求的实际输入或最终输出长度。

图3展示了两个请求：请求A的最大序列长度为2048，请求B的最大序列长度为512。现有系统中的块预分配方案有三个主要的内存浪费来源：为未来的标记保留的槽位、由于对潜在最大序列长度的过度配置而导致的内部碎片，以及来自内存分配器（如伙伴分配器）的外部碎片。外部碎片永远不会用于生成的标记，这在处理请求之前是已知的。内部碎片也保持未使用，但这只有在请求完成采样后才会意识到。它们都是纯粹的内存浪费。尽管保留的内存最终会被使用，但在整个请求持续期间保留这块空间，尤其是当保留的空间很大时，会占用本可以用于处理其他请求的空间。我们在实验中可视化了内存浪费的平均百分比，如图2所示，揭示了之前系统中的实际有效内存可以低至20.4%。




图 4. vLLM 系统概述。

尽管压缩 [54] 被提议作为解决碎片化的潜在方案，但在性能敏感的 LLM 服务系统中执行压缩是不切实际的，因为存在庞大的 KV 缓存。即使进行了压缩，为每个请求预分配的块空间也阻止了在现有内存管理系统中对解码算法的内存共享。

4 方法

在这项工作中，我们开发了一种新的注意力算法，PagedAttention，并构建了一个 LLM 服务引擎 vLLM，以应对 §3 中概述的挑战。vLLM 的架构如图 4 所示。vLLM 采用集中式调度器来协调分布式 GPU 工作者的执行。KV 缓存管理器以分页方式有效管理 KV 缓存，这得益于 PagedAttention。具体而言，KV 缓存管理器通过集中式调度器发送的指令管理 GPU 工作者上的物理 KV 缓存内存。

接下来，我们在 §4.1 中描述 PagedAttention 算法。随后，我们在 §4.2 中展示 KV 缓存管理器的设计，以及它如何在 §4.3 中促进 PagedAttention。然后，我们展示了该设计如何促进各种解码方法的有效内存管理 (§4.4) 以及如何处理可变长度的输入和输出序列 (§4.5)。最后，我们展示了 vLLM 的系统设计在分布式环境中的工作原理 (§4.6)。

4.1 分页注意力

为了应对 §3 中的内存挑战，我们引入了 PagedAttention，这是一种受操作系统中经典分页思想 [25] 启发的注意力算法。与传统的注意力算法不同，PagedAttention 允许在不连续的内存空间中存储连续的键和值。具体而言，PagedAttention 将每个序列的 KV 缓存划分为 KV 块。每个块包含固定数量的令牌的键和值向量，¹我们将其称为 KV

¹In Transformer, each token has a set of key and value vectors across layers and attention heads within a layer. All the key and value vectors can be managed together within a single KV block, or the key and value vectors at different heads and layers can each have a separate block and be managed in separate block tables. The two designs have no performance difference and we choose the second one for easy implementation.




图 5. PagedAttention 算法的示意图，其中注意力键和值向量作为不连续的块存储在内存中。

块大小 (B)。表示关键块 $K_j = (k_{(j-1)B+1}, \dots, k_{jB})$ 和值块 $V_j = (v_{(j-1)B+1}, \dots, v_{jB})$ 。公式 4 中的注意力计算可以转化为以下块级计算：

$$A_{ij} = \frac{\exp(q_i^T K_j / \sqrt{d})}{\sum_{t=1}^{\lceil i/B \rceil} \exp(q_i^T K_t / \sqrt{d})}, o_i = \sum_{j=1}^{\lceil i/B \rceil} V_j A_{ij}^T, \quad (4)$$

其中 $A_{ij} = (a_{i,(j-1)B+1}, \dots, a_{i,jB})$ 是 j 号 KV 块的注意力分数的行向量。

在注意力计算过程中，PagedAttention 内核分别识别并获取不同的 KV 块。我们在图 5 中展示了 PagedAttention 的一个示例：键和值向量分布在三个块中，并且这三个块在物理内存中并不连续。每次，内核将查询标记（“forth”）的查询向量 q_i 与一个块中的键向量 K_j （例如，块 0 中的“Four score and seven”的键向量）相乘，以计算注意力分数 A_{ij} ，然后将 A_{ij} 与一个块中的值向量 V_j 相乘，以得出最终的注意力输出 o_i 。

总之，PagedAttention 算法允许 KV 块存储在不连续的物理内存中，这使得 vLLM 中的分页内存管理更加灵活。

4.2 KV 缓存管理器

vLLM 的内存管理器背后的关键思想类似于操作系统中的虚拟内存 [25]。操作系统将内存划分为固定大小的页面，并将用户程序的逻辑页面映射到物理页面。连续的逻辑页面可以对应于不连续的物理内存页面，从而允许用户程序像访问连续内存一样访问内存。此外，物理内存空间不需要提前完全保留，使操作系统能够根据需要动态分配物理页面。vLLM 利用虚拟内存背后的思想来管理 LLM 服务中的 KV 缓存。在 PagedAttention 的支持下，我们将 KV 缓存组织为固定大小的 KV 块，类似于虚拟内存中的页面。

请求的 KV 缓存表示为一系列逻辑 KV 块，从左到右填充，随着新标记及其 KV 缓存的生成。最后一个 KV 块的未填充位置保留用于未来的生成。在 GPU 工作节点上，一个块引擎分配一块连续的 GPU DRAM 并

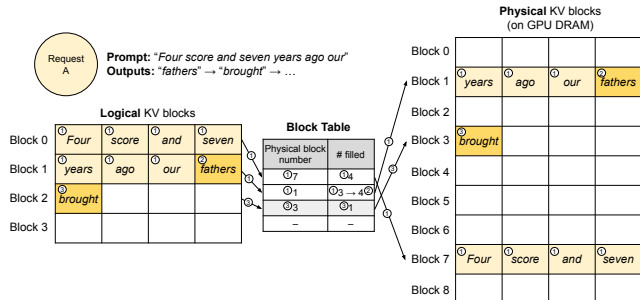


图6. vLLM中的块表翻译。

将其划分为物理 KV 块（这在 CPU RAM 上也用于交换；见 §4.5）。KV 块管理器还维护块表——每个请求的逻辑和物理 KV 块之间的映射。每个块表条目记录逻辑块的相应物理块和已填充位置的数量。将逻辑和物理 KV 块分开允许 vLLM 动态增长 KV 缓存内存，而无需提前为所有位置保留内存，这消除了现有系统中大部分内存浪费，如图 2 所示。

4.3 使用 PagedAttention 和 vLLM 解码

接下来，我们通过一个示例（如图6所示）来演示vLLM如何执行PagedAttention并在单个输入序列的解码过程中管理内存：1○与操作系统的虚拟内存一样，vLLM不需要最初为最大可能生成的序列长度保留内存。相反，它仅保留必要的KV块，以容纳在提示计算过程中生成的KV缓存。在这种情况下，提示有7个标记，因此vLLM将前2个逻辑KV块（0和1）映射到2个物理KV块（7和1）。在预填充步骤中，vLLM使用常规自注意力算法（例如，[13]）生成提示和第一个输出标记的KV缓存。然后，vLLM将前4个标记的KV缓存存储在逻辑块0中，将后3个标记存储在逻辑块1中。剩余的槽位保留用于后续的自回归生成阶段。2○在第一次自回归解码步骤中，vLLM在物理块7和1上使用PagedAttention算法生成新标记。由于最后一个逻辑块中还有一个槽位可用，新生成的KV缓存存储在那里，并且块表的#filled记录被更新。3○在第二次解码步骤中，由于最后一个逻辑块已满，vLLM将新生成的KV缓存存储在一个新的逻辑块中；vLLM为其分配一个新的物理块（物理块3），并在块表中存储此映射。

在全球范围内，对于每次解码迭代，vLLM 首先选择一组候选序列进行批处理（更多内容见 §4.5），并为新需要的逻辑块分配物理块。然后，vLLM 将当前迭代的所有输入标记（即提示阶段的所有标记）连接在一起。




图7. 在vLLM中同时存储两个请求的KV缓存。

请求和生成阶段请求的最新令牌）作为一个序列并将其输入到LLM中。在LLM的计算过程中，vLLM使用Page dAttention内核访问以逻辑KV块形式存储的先前KV缓存，并将新生成的KV缓存保存到物理KV块中。在KV块内存存储多个令牌（块大小 > 1）使PagedAttention内核能够并行处理跨更多位置的KV缓存，从而提高硬件利用率并减少延迟。然而，较大的块大小也会增加内存碎片。我们在§7.2中研究块大小的影响。

再次，vLLM 动态地将新的物理块分配给逻辑块，因为生成了更多的令牌及其 KV 缓存。由于所有块都是从左到右填充，并且只有在所有先前的块都满时才分配新的物理块，vLLM 将请求的所有内存浪费限制在一个块内，因此它可以有效地利用所有内存，如图 2 所示。这允许更多的请求适应内存以进行批处理，从而提高吞吐量。一旦请求完成其生成，其 KV 块可以被释放以存储其他请求的 KV 缓存。在图 7 中，我们展示了 vLLM 管理两个序列内存的示例。这两个序列的逻辑块被映射到 GPU 工作器中块引擎保留的空间内的不同物理块。两个序列的相邻逻辑块不需要在物理 GPU 内存中是连续的，物理块的空间可以被两个序列有效利用。

4.4 应用到其他解码场景

§4.3展示了PagedAttention和vLLM如何处理基本的解码算法，例如贪婪解码和采样，这些算法以一个用户提示作为输入并生成一个单一的输出序列。在许多成功的LLM应用中[18, 34]，LLM服务必须提供更复杂的解码场景，这些场景表现出复杂的访问模式和更多的内存共享机会。我们在本节中展示了vLLM在这些场景中的一般适用性。

并行采样。在基于LLM的程序助手[6, 18]中，LLM为单个输入提示生成多个采样输出；用户可以从各种候选中选择喜欢的输出。到目前为止，我们隐含地假设一个请求




图8. 并行采样示例。

生成一个单一序列。在本文的其余部分，我们假设一个请求生成多个序列的更一般情况。在并行采样中，一个请求包括多个共享相同输入提示的样本，从而允许提示的KV缓存也被共享。通过其PagedAttention和分页内存管理，vLLM可以轻松实现这种共享并节省内存。

图8展示了两个输出的并行解码示例。由于两个输出共享相同的提示，我们只在提示阶段为提示状态保留一个副本的空间；两个序列的提示逻辑块映射到相同的物理块：两个序列的逻辑0和1分别映射到物理块7和1。由于单个物理块可以映射到多个逻辑块，我们为每个物理块引入了引用计数。在这种情况下，物理块7和1的引用计数均为2。在生成阶段，两个输出采样不同的输出标记，并需要为KV缓存提供单独的存储。vLLM在需要被多个序列修改的物理块上实现了按块粒度的写时复制机制，类似于操作系统虚拟内存中的写时复制技术（例如，在分叉进程时）。具体来说，在图8中，当样本A1需要写入其最后一个逻辑块（逻辑块1）时，vLLM识别到相应物理块（物理块1）的引用计数大于1；它分配一个新的物理块（物理块3），指示块引擎从物理块1复制信息，并将引用计数减少到1。接下来，当样本A2写入物理块1时，引用计数已经减少到1；因此A2直接将其新生成的KV缓存写入物理块1。

总之，vLLM使得在多个输出样本之间共享用于存储提示的KV缓存的大部分空间成为可能，唯一的例外是由写时复制机制管理的最终逻辑块。通过在多个样本之间共享物理块，内存使用量可以大大减少，特别是对于较长的输入提示。

束搜索。在像机器翻译 [59] 这样的 LLM 任务中，用户期望 LLM 输出最合适的前- k 个翻译。束搜索 [49] 被广泛用于从 LLM 解码最可能的输出序列，因为它减轻了完全遍历计算的复杂性。




图 9. 波束搜索示例。

样本空间。该算法依赖于束宽参数 k ，该参数决定了在每一步保留的顶级候选者数量。在解码过程中，束搜索通过考虑所有可能的标记来扩展束中的每个候选序列，使用 LLM 计算它们各自的概率，并从 $k \cdot |V|$ 个候选者中保留最有可能的前- k 个序列，其中 $|V|$ 是词汇表的大小。

与并行解码不同，束搜索不仅共享初始提示块，还共享不同候选者之间的其他块，并且共享模式会随着解码过程的推进而动态变化，类似于由复合分叉创建的操作系统中的过程树。图9展示了vLLM如何管理束搜索示例中的KV块，使用 $k = 4$ 。在虚线所示的迭代之前，每个候选序列都使用了4个完整的逻辑块。所有束候选者共享第一个块0（即提示）。候选者3从第二个块开始与其他候选者偏离。候选者0-2共享前3个块，并在第四个块处分歧。在后续迭代中，前4个最可能的候选者均来自候选者1和2。由于原始候选者0和3不再是前列候选者，它们的逻辑块被释放，相应物理块的引用计数减少。vLLM释放所有引用计数达到0的物理块（块2、4、5、8）。然后，vLLM分配新的物理块（块9-12）以存储来自新候选者的新KV缓存。现在，所有候选者共享块0、1、3；候选者0和1共享块6，候选者2和3进一步共享块7。

以前的 LLM 服务系统需要在光束候选者之间频繁地复制 KV 缓存。例如，在图 9 所示的情况下，在虚线之后，候选者 3 需要复制候选者 2 的大部分 KV 缓存以继续生成。通过 vLLM 的物理块共享，这种频繁的内存复制开销显著减少。在 vLLM 中，不同光束候选者的大多数块可以共享。仅在新生成的标记位于旧共享块内时，才会应用写时复制机制，如在并行解码中。这仅涉及复制一个数据块。

共享前缀。通常，LLM 用户提供一个（长）任务描述，包括指令和示例输入输出，也称为系统提示 [36]。该描述与实际任务输入连接在一起，形成请求的提示。LLM 根据生成输出。

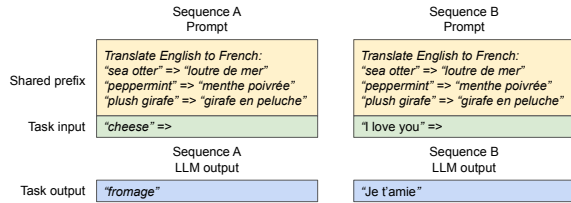


图10. 机器翻译的共享提示示例。示例摘自[5]。

在完整提示上。图10显示了一个示例。此外，共享前缀可以通过提示工程进一步调整，以提高下游任务的准确性[26, 27]。

对于这种类型的应用，许多用户提示共享一个前缀，因此 LLM 服务提供商可以提前存储前缀的 KV 缓存，以减少在前缀上花费的冗余计算。在 vLLM 中，这可以通过为一组预定义的共享前缀保留一组物理块来方便地实现，就像操作系统在进程之间处理共享库一样。具有共享前缀的用户输入提示可以简单地将其逻辑块映射到缓存的物理块（最后一个块标记为写时复制）。提示阶段的计算只需要在用户的任务输入上执行。

混合解码方法。前面讨论的解码方法表现出多样的内存共享和访问模式。然而，vLLM 促进了对具有不同解码偏好的请求的同时处理，而现有系统无法高效地做到这一点。这是因为 vLLM 通过一个公共映射层隐藏了不同序列之间复杂的内存共享，该层将逻辑块转换为物理块。LLM 及其执行内核仅看到每个序列的物理块 ID 列表，而无需处理跨序列的共享模式。与现有系统相比，这种方法扩大了对具有不同采样要求的请求的批处理机会，最终提高了系统的整体吞吐量。

4.5 调度与抢占

当请求流量超过系统的容量时，vLLM 必须优先处理一部分请求。在 vLLM 中，我们采用先到先服务（FCFS）调度策略来处理所有请求，确保公平性并防止饥饿。当 vLLM 需要抢占请求时，它确保最早到达的请求优先得到服务，而最新的请求优先被抢占。

LLM服务面临一个独特的挑战：LLM的输入提示在长度上可能有显著差异，而生成的输出长度是未知的，取决于输入提示和模型。随着请求数量及其输出的增加，vLLM可能会耗尽GPU的物理块来存储新生成的KV缓存。vLLM需要在这方面回答两个经典问题。

上下文：（1）应该驱逐哪些块？（2）如果再次需要，如何恢复被驱逐的块？通常，驱逐策略使用启发式方法来预测未来将最远访问哪个块，并驱逐该块。由于在我们的情况下，我们知道一个序列的所有块是一起访问的，因此我们实现了一种全有或全无的驱逐策略，即要么驱逐一个序列的所有块，要么不驱逐任何块。此外，在一个请求中多个序列（例如，在一次束搜索请求中的束候选）作为一个序列组进行联合调度。由于这些序列之间可能存在内存共享，因此一个序列组内的序列总是一起被抢占或重新调度。为了回答第二个问题，即如何恢复被驱逐的块，我们考虑两种技术：

交换。这是大多数虚拟内存实现使用的经典技术，它将被驱逐的页面复制到磁盘上的交换空间。在我们的案例中，我们将被驱逐的块复制到CPU内存。如图4所示，除了GPU块分配器，vLLM还包括一个CPU块分配器来管理交换到CPU RAM的物理块。当vLLM耗尽用于新令牌的空闲物理块时，它会选择一组序列进行驱逐并将其KV缓存转移到CPU。一旦它抢占了一个序列并驱逐了其块，vLLM将停止接受新请求，直到所有被抢占的序列完成。一旦请求完成，其块将从内存中释放，被抢占序列的块将被带回以继续处理该序列。请注意，使用这种设计，交换到CPU RAM的块数永远不会超过GPU RAM中物理块的总数，因此CPU RAM上的交换空间受到分配给KV缓存的GPU内存的限制。

重新计算。在这种情况下，当被抢占的序列重新调度时，我们简单地重新计算KV缓存。请注意，重新计算的延迟可能显著低于原始延迟，因为在解码时生成的令牌可以与原始用户提示连接为一个新提示——它们在所有位置的KV缓存可以在一个提示阶段迭代中生成。

交换和重新计算的性能取决于 CPU RAM 和 GPU 内存之间的带宽以及 GPU 的计算能力。我们在 §7.3 中检查交换和重新计算的速度。

4.6 分布式执行

许多大型语言模型（LLMs）的参数大小超过单个GPU的容量[5, 9]。因此，有必要将它们分配到分布式GPU上，并以模型并行的方式执行[28, 63]。这需要一个能够处理分布式内存的内存管理器。vLLM在分布式环境中有效，通过支持广泛使用的Megatron-LM风格的张量模型并行策略在变换器上[47]。该策略遵循SPMD（单程序多数据）执行计划，其中线性层被分割。

表1. 模型大小和服务配置。

Model size	13B	66B	175B
GPUs	A100	4×A100	8×A100-80GB
Total GPU memory	40 GB	160 GB	640 GB
Parameter size	26 GB	132 GB	346 GB
Memory for KV cache	12 GB	21 GB	264 GB
Max. # KV cache slots	15.7K	9.7K	60.1K

进行块状矩阵乘法，GPU通过全规约操作不断同步中间结果。具体来说，注意力算子在注意力头维度上被拆分，每个SPMD进程负责多头注意力中一部分注意力头。

我们观察到，即使在模型并行执行的情况下，每个模型分片仍然处理相同的一组输入标记，因此需要为相同的位置使用KV缓存。因此，vLLM在集中调度器中具有一个单一的KV缓存管理器，如图4所示。不同的GPU工作节点共享该管理器，以及从逻辑块到物理块的映射。这个公共映射允许GPU工作节点使用调度器为每个输入请求提供的物理块来执行模型。尽管每个GPU工作节点具有相同的物理块ID，但一个工作节点仅存储其对应注意力头的一部分KV缓存。

在每一步中，调度器首先为批次中的每个请求准备带有输入令牌ID的消息，以及每个请求的块表。接下来，调度器将此控制消息广播给GPU工作节点。然后，GPU工作节点开始使用输入令牌ID执行模型。在注意力层中，GPU工作节点根据控制消息中的块表读取KV缓存。在执行过程中，GPU工作节点在没有调度器协调的情况下，通过全归约通信原语同步中间结果，如[47]所示。最后，GPU工作节点将本次迭代的采样令牌发送回调度器。总之，GPU工作节点不需要在内存管理上进行同步，因为它们只需在每次解码迭代开始时接收所有内存管理信息以及步骤输入。

5 实施

vLLM是一个端到端的服务系统，具有FastAPI[15]前端和基于GPU的推理引擎。前端扩展了OpenAI API[34]接口，允许用户为每个请求自定义采样参数，例如最大序列长度和束宽 k 。vLLM引擎由8.5K行Python和2K行C++/CUDA代码编写。我们在Python中开发与控制相关的组件，包括调度器和块管理器，同时为关键操作（如PagedAttention）开发自定义CUDA内核。对于模型执行器，我们实现了流行的LLM，如GPT[5]、OPT[62]和LLaMA[52]。

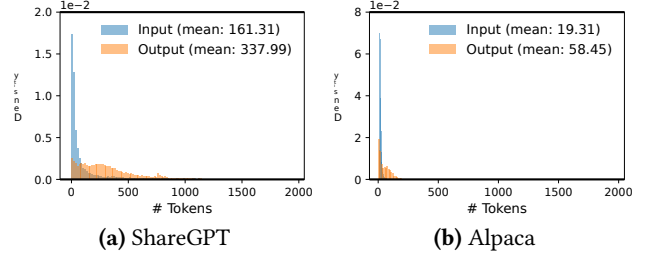


图11. (a) ShareGPT和(b) Alpaca数据集的输入和输出长度分布。

PyTorch[39]和Transformers[58]。我们使用NCCL[32]进行分布式GPU工作节点之间的张量通信。

5.1 内核级优化

由于PagedAttention引入的内存访问模式在现有系统中得不到有效支持，我们开发了几个GPU内核来优化它。(1) 融合重塑和块写入。在每个Transformer层中，新的KV缓存被分割成块，重塑为优化块读取的内存布局，然后保存在块表指定的位置。为了最小化内核启动开销，我们将它们融合为一个单一的内核。(2) 融合块读取和注意力。我们调整了FasterTransformer[31]中的注意力内核，以根据块表读取KV缓存并实时执行注意力操作。为了确保合并内存访问，我们分配一个GPU warp来读取每个块。此外，我们增加了对请求批次中可变序列长度的支持。(3) 融合块复制。由写时复制机制发出的块复制操作可能会在不连续的块上操作。如果我们使用cudaMemcpyAsync API，这可能导致大量小数据移动的调用。为了减轻开销，我们实现了一个内核，将不同块的复制操作批处理为一个单一的内核启动。

5.2 支持各种解码算法

vLLM实现了多种解码算法，使用三种关键方法：分叉、追加和释放。分叉方法从现有序列创建一个新序列。追加方法将一个标记附加到序列中。最后，释放方法删除序列。例如，在并行采样中，vLLM使用分叉方法从单个输入序列创建多个输出序列。然后，它在每次迭代中使用追加方法向这些序列添加新标记，并使用释放方法删除满足停止条件的序列。vLLM在束搜索和前缀共享中也应用了相同的策略。我们相信，未来的解码算法也可以通过结合这些方法来支持。

6 评估

在本节中，我们评估了vLLM在各种工作负载下的性能。

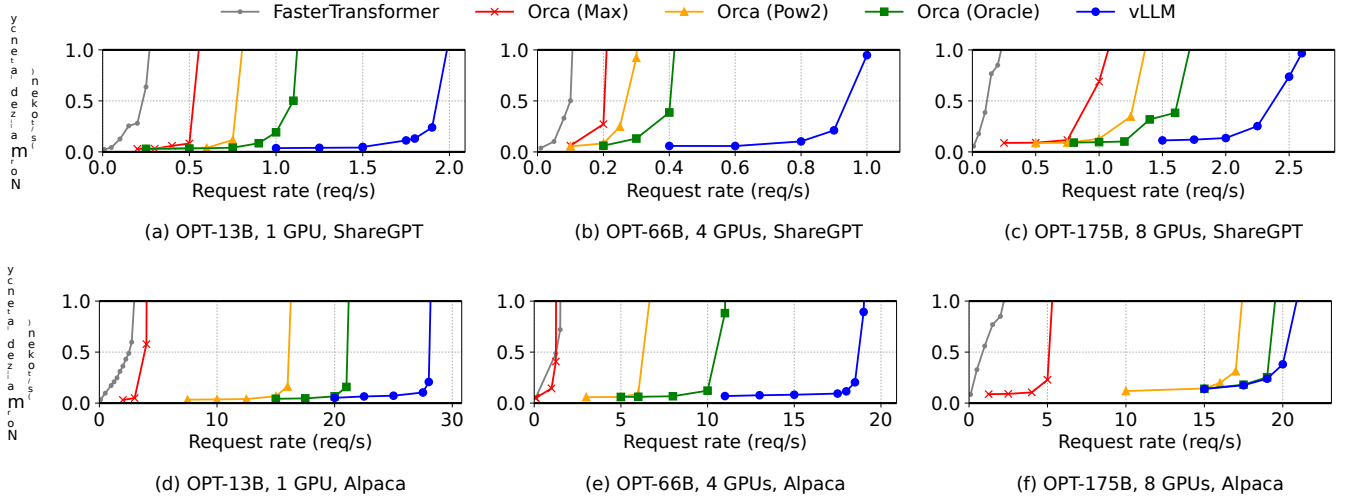


图12. 在ShareGPT和Alpaca数据集上使用OPT模型进行单序列生成




图13. 在为ShareGPT (2 req/s) 和Alpaca (30 req/s) 跟踪服务OPT-13B时, 批量请求的平均数量。

6.1 实验设置

模型和服务器配置。我们使用具有13B、66B和175B参数的OPT [62]模型, 以及具有13B参数的LLaMA [52]进行评估。13B和66B是LLM的热门规模, 如LLM排行榜[38]所示, 而175B是著名的GPT-3 [5]模型的规模。在我们所有的实验中, 我们在Google Cloud Platform上使用配备NVIDIA A100 GPU的A2实例。详细的模型规模和服务器配置见表1。

工作负载。我们基于ShareGPT [51]和Alpaca [50]数据集合成工作负载, 这些数据集包含真实LLM服务的输入和输出文本。ShareGPT数据集是用户与ChatGPT [35]共享对话的集合。Alpaca数据集是由GPT-3.5通过自我指导[57]生成的指令数据集。我们对数据集进行分词, 并使用它们的输入和输出长度来合成客户端请求。如图11所示, ShareGPT数据集的输入提示平均比Alpaca数据集长8.4 \times , 输出长5.8 \times , 且方差更高。由于这些数据集不包含时间戳, 我们使用不同请求速率的泊松分布生成请求到达时间。

基线 1: FasterTransformer。FasterTransformer [31] 是一个高度优化延迟的分布式推理引擎。

由于FasterTransformer没有自己的调度器, 我们实现了一个自定义调度器, 采用类似于现有服务系统 (如Triton [30]) 的动态批处理机制。具体来说, 我们根据GPU内存容量为每个实验设置一个尽可能大的最大批量大小 B 。调度器最多接受 B 个最早到达的请求, 并将批量发送给FasterTransformer进行处理。

基线 2: Orca。Orca [60] 是一个针对吞吐量优化的最先进 LLM 服务系统。由于 Orca 不能公开使用, 我们实现了自己的 Orca 版本。我们假设 Orca 使用伙伴分配算法来确定存储 KV 缓存的内存地址。我们根据其请求输出过度保留空间的程度实现了三个版本的 Orca:

- Orca (Oracle)。我们假设系统知道将为请求实际生成的输出长度。这显示了Orca的上限性能, 而在实践中是不可实现的。
- Orca (Pow2)。我们假设系统最多为输出过度保留空间 $2\times$ 。例如, 如果真实输出长度为 25, 则为输出保留 32 个位置。
- Orca (最大)。我们假设系统始终保留空间, 直到模型的最大序列长度, 即2048个标记。

关键指标。我们专注于服务吞吐量。具体来说, 使用不同请求速率的工作负载, 我们测量系统的标准化延迟, 即每个请求的端到端延迟的均值除以其输出长度, 如Orca [60]所示。高吞吐量的服务系统应在高请求速率下保持低标准化延迟。对于大多数实验, 我们使用1小时的追踪数据进行评估。作为例外, 由于成本限制, 我们对OPT-175B模型使用15分钟的追踪数据。

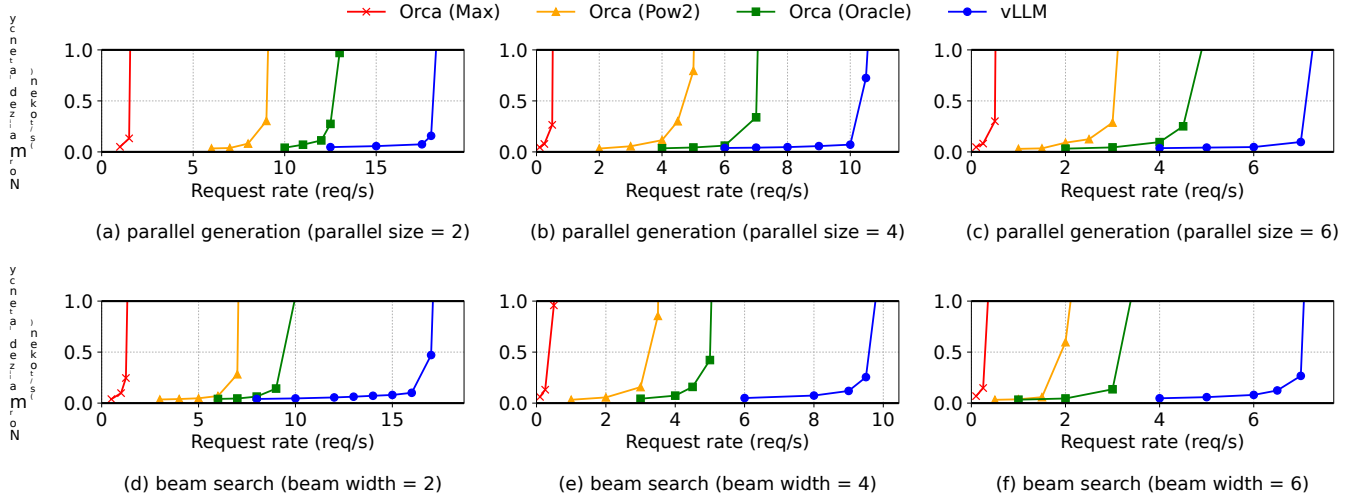


图14. 在Alpaca数据集上使用OPT-13B进行并行生成和束搜索。

6.2 基本抽样

我们在三个模型和两个数据集上评估了 vLLM 的基本采样性能（每个请求一个样本）。图 12 的第一行显示了 ShareGPT 数据集上的结果。曲线表明，随着请求速率的增加，延迟最初以缓慢的速度增加，但随后突然爆炸。这可以归因于当请求速率超过服务系统的容量时，队列长度不断无限增长，请求的延迟也随之增加。

在ShareGPT数据集上，vLLM能够维持比Orca（Oracle）高1.7 \times –2.7 \times 的请求速率，比Orca（Max）高2.7 \times –8 \times ，同时保持类似的延迟。这是因为vLLM的PagedAttention能够有效管理内存使用，从而使得批处理比Orca更多的请求。例如，如图13a所示，对于OPT-13B，vLLM同时处理的请求比Orca（Oracle）多2.2 \times 个，比Orca（Max）多4.3 \times 个。与FasterTransformer相比，vLLM能够维持高达22 \times 的请求速率，因为FasterTransformer没有利用细粒度调度机制，并且像Orca（Max）一样低效地管理内存。

图12和图13b的第二行显示了在Alpaca数据集上的结果，其趋势与ShareGPT数据集相似。一个例外是图12(f)，在这里vLLM相对于Orca（Oracle）和Orca（Pow2）的优势不那么明显。这是因为OPT-175B的模型和服务器配置（表1）允许有大量GPU内存空间可用于存储KV缓存，而Alpaca数据集的序列较短。在这种设置下，尽管它们的内存管理效率较低，Orca（Oracle）和Orca（Pow2）仍然可以批量处理大量请求。因此，系统的性能变得以计算为限制，而不是以内存为限制。




图15. 在为Alpaca跟踪服务OPT-13B时，通过共享KV块节省的平均内存量。


6.3 并行采样和束搜索

我们评估了在 Page-dAttention 中内存共享的有效性，使用了两种流行的采样方法：并行采样和束搜索。在并行采样中，请求中的所有并行序列可以共享提示的 KV 缓存。如图 14 的第一行所示，随着采样序列数量的增加，vLLM 相对于 Orca 基线带来了更多的改进。同样，图 14 的第二行显示了不同束宽下束搜索的结果。由于束搜索允许更多的共享，vLLM 展现出更大的性能优势。vLLM 在 OPT-13B 和 Alpaca 数据集上相对于 Orca（Oracle）的改进，从基本采样中的 1.3 \times 到束搜索中宽度为 6 的 2.3 \times 。

图15绘制了内存节省的数量，计算方法是通过共享节省的块数除以不共享的总块数。我们在并行采样中显示了6.1% - 9.8%的内存节省，在束搜索中显示了37.6% - 55.2%的内存节省。在与ShareGPT数据集进行的相同实验中，我们在并行采样中观察到了16.2% - 30.5%的内存节省，在束搜索中观察到了44.3% - 66.3%的内存节省。

6.4 共享前缀

我们探讨了 vLLM 在不同输入提示之间共享前缀的情况下的有效性，如下所示。



(a) 1-shot prefix prompt (b) 5-shot prefix prompt

图16. 翻译工作负载，其中输入提示共享一个公共前缀。前缀包括 (a) 1 个示例，包含 80 个标记，或 (b) 5 个示例，包含 341 个标记。

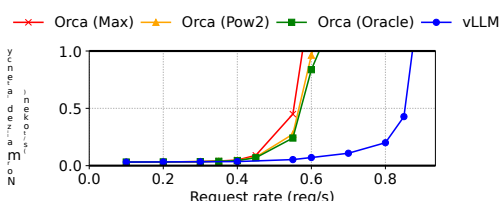


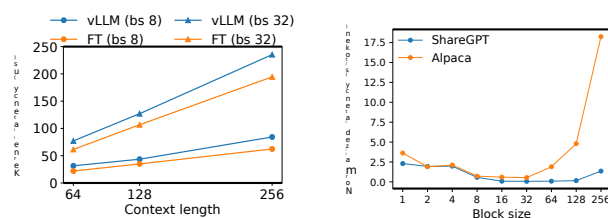
图17. 聊天机器人工作负载的性能。

图10. 对于模型，我们使用LLaMA-13B [52]，它是多语言的。对于工作负载，我们使用WMT16 [4] 英语到德语翻译数据集，并合成两个前缀，其中包括一个指令和一些翻译示例。第一个前缀包含一个示例（即一次性），而另一个前缀包含5个示例（即少量）。如图16 (a) 所示，当共享一次性前缀时，vLLM的吞吐量比Orca (Oracle) 高出1.67 \times 。此外，当共享更多示例时（图16 (b)），vLLM的吞吐量比Orca (Oracle) 高出3.58 \times 。

6.5 聊天机器人

聊天机器人 [8, 19, 35] 是大型语言模型 (LLMs) 最重要的应用之一。为了实现聊天机器人，我们通过将聊天历史和最后的用户查询连接成一个提示来让模型生成响应。我们使用 ShareGPT 数据集合成聊天历史和用户查询。由于 OPT-13B 模型的上下文长度有限，我们将提示截断为最后 1024 个标记，并让模型最多生成 1024 个标记。我们不在不同的对话轮次之间存储 KV 缓存，因为这样会占用对话轮次之间其他请求的空间。

图17显示，vLLM可以支持比三个Orca基线高出2 \times 的请求速率。由于ShareGPT数据集包含许多长对话，大多数请求的输入提示有1024个标记。由于伙伴分配算法，Orca基线为请求输出保留1024个标记的空间，无论它们如何预测输出长度。因此，三个Orca基线的表现相似。相比之下，vLLM可以有效地



(a) 注意力核的延迟。(b) 不同块大小的端到端延迟。

图18. 消融实验。

处理长提示，因为 PagedAttention 解决了内存碎片和保留的问题。

7 消融研究

在本节中，我们研究vLLM的各个方面，并通过消融实验评估我们所做的设计选择。

7.1 内核微基准测试

动态块映射在PagedAttention中影响涉及存储的KV缓存的GPU操作的性能，即块读/写和注意力。与现有系统相比，我们的GPU内核 (§5) 涉及访问块表、执行额外分支和处理可变序列长度的额外开销。如图18a所示，这导致注意力内核延迟比高度优化的FasterTransformer实现高出20-26%。我们认为这个开销很小，因为它只影响注意力操作符，而不影响模型中的其他操作符，如线性。尽管有开销，PagedAttention使vLLM在端到端性能上显著超越FasterTransformer (§6)。

7.2 块大小的影响

块大小的选择会对 vLLM 的性能产生重大影响。如果块大小太小，vLLM 可能无法充分利用 GPU 在读取和处理 KV 缓存时的并行性。如果块大小太大，内部碎片化增加，共享的概率降低。

在图18b中，我们评估了vLLM在不同块大小下的性能，使用ShareGPT和Alpaca的基本采样跟踪，固定请求速率。在ShareGPT跟踪中，块大小从16到128的表现最佳。在Alpaca跟踪中，虽然块大小16和32表现良好，但较大的块大小显著降低了性能，因为序列变得比块大小短。在实践中，我们发现块大小16足够大，可以有效利用GPU，同时又足够小，以避免在大多数工作负载中出现显著的内部碎片。因此，vLLM将其默认块大小设置为16。




图19. (a) 不同块大小的重新计算和交换的开销。(b) 在相同请求速率下使用ShareGPT跟踪服务OPT-13B的性能。

7.3 比较重新计算和交换

vLLM 支持重计算和交换作为其恢复机制。为了理解这两种方法之间的权衡，我们评估了它们的端到端性能并对其开销进行了微基准测试，如图 19 所示。我们的结果显示，使用小块大小时，交换会产生过高的开销。这是因为小块大小通常会导致 CPU 和 GPU 之间进行大量的小数据传输，从而限制了有效的 PCIe 带宽。相比之下，重计算的开销在不同块大小之间保持不变，因为重计算不使用 KV 块。因此，当块大小较小时，重计算更高效，而当块大小较大时，交换更高效，尽管重计算的开销从未超过交换延迟的 20%。对于 16 到 64 的中等块大小，这两种方法表现出可比的端到端性能。

8 讨论

将虚拟内存和分页技术应用于其他 GPU 工作负载。虚拟内存和分页的理念对于管理 LLM 服务中的 KV 缓存是有效的，因为该工作负载需要动态内存分配（因为输出长度事先未知），并且其性能受限于 GPU 内存容量。然而，这并不适用于每个 GPU 工作负载。例如，在 DNN 训练中，张量形状通常是静态的，因此内存分配可以提前优化。另一个例子是在服务非 LLM 的 DNN 时，内存效率的提高可能不会带来任何性能提升，因为性能主要受计算限制。在这种情况下，引入 vLLM 的技术可能会由于内存间接访问和不连续块内存的额外开销而降低性能。然而，我们很高兴看到 vLLM 的技术被应用于与 LLM 服务具有相似特性的其他工作负载。

在应用虚拟内存和分页时的 LLM 特定优化。vLLM 通过利用特定于应用的语义重新解释和增强了虚拟内存和分页的概念。一个例子是 vLLM 的全有或全无。

交换策略，利用处理请求需要将其所有对应的令牌状态存储在 GPU 内存中的事实。另一个例子是重新计算方法以恢复被驱逐的块，这在操作系统中是不可行的。此外，vLLM 通过将内存访问操作的 GPU 内核与其他操作（如注意力）融合，减轻了分页中内存间接访问的开销。

9 相关工作

通用模型服务系统。模型服务近年来一直是一个活跃的研究领域，提出了许多系统来解决深度学习模型部署的不同方面。Clipper [11]、TensorFlow Serving [33]、Nexus [45]、InferLine [10] 和 Clockwork [20] 是一些早期的通用模型服务系统。它们研究了单个或多个模型的批处理、缓存、放置和调度。最近，DVABatch [12] 引入了多入口多出口的批处理。REEF [21] 和 Shepherd [61] 提出了服务的抢占。AlpaServe [28] 利用模型并行性进行统计复用。然而，这些通用系统未能考虑 LLM 推理的自回归特性和令牌状态，导致错失优化机会。

专门的变压器服务系统。由于变压器架构的重要性，已经开发了许多专门的服务系统。这些系统利用 GPU 内核优化 [1, 29, 31, 56]、先进的批处理机制 [14, 60]、模型并行性 [1, 41, 60] 和参数共享 [64] 来实现高效服务。其中，Orca [60] 与我们的方法最为相关。

与 Orca 的比较。Orca [60] 中的迭代级调度和 vLLM 中的 PagedAttention 是互补的技术：虽然这两个系统都旨在提高 GPU 利用率，从而提高 LLM 服务的吞吐量，但 Orca 通过调度和交错请求来实现这一点，以便可以并行处理更多请求，而 vLLM 则通过增加内存利用率来实现，使得更多请求的工作集能够适应内存。通过减少内存碎片和启用共享，vLLM 可以并行处理更多请求，并实现与 Orca 相比的 2-4x 加速。实际上，像 Orca 那样对请求进行细粒度调度和交错使得内存管理变得更加具有挑战性，这使得 vLLM 中提出的技术变得更加重要。

内存优化。加速器的计算能力与内存容量之间日益扩大的差距使得内存成为训练和推理的瓶颈。交换 [23, 42, 55]、重计算 [7, 24] 及其组合 [40] 已被用于减少训练的峰值内存。值得注意的是，FlexGen [46] 研究了如何在 LLM 推理中交换权重和令牌状态，使用 {v*}。

有限的GPU内存，但它并不针对在线服务设置。OLLA [48] 优化张量的生命周期和位置以减少碎片化，但它不进行细粒度的块级管理或在线服务。FlashAttention [13] 应用切片和内核优化以减少注意力计算的峰值内存并降低I/O成本。本文在在线服务的背景下引入了一种新的块级内存管理理念。

10 结论

本文提出了PagedAttention，一种新的注意力算法，允许将注意力键和值存储在非连续的分页内存中，并介绍了vLLM，一个具有高吞吐量的LLM服务系统，得益于PagedAttention实现的高效内存管理。受到操作系统的启发，我们展示了如何将现有技术（如虚拟内存和写时复制）调整为高效管理KV缓存并处理LLM服务中的各种解码算法。我们的实验表明，vLLM在吞吐量上比最先进的系统提高了2-4×。

致谢

我们要感谢刘晓轩、陈志峰、黄燕平、匿名的SOSP评审以及我们的指导者周立东，感谢他们的深刻反馈。这项研究部分得到了Andreessen Horowitz、Anyscale、Astronomer、Google、IBM、Intel、Lacework、Microsoft、穆罕默德·本·扎耶德人工智能大学、三星SDS、Uber和VMware的资助。

参考文献

[1] Reza Yazdani Aminabadi, Samyam Rajbhandari, Minjia Zhang, Ammar Ahmad Awan, Cheng Li, Du Li, Elton Zheng, Jeff Rasley, Shaden Smith, Olatunji Ruwase 等. 2022. DeepSpeed 推理：在前所未有的规模上实现高效的变换器模型推理. arXiv 预印本 arXiv:2207.00032 (2022). [2] Jimmy Lei Ba, Jamie Ryan Kiros 和 Geoffrey E Hinton. 2016. 层归一化. arXiv 预印本 arXiv:1607.06450 (2016). [3] Yoshua Bengio, Réjean Ducharme 和 Pascal Vincent. 2000. 一种神经概率语言模型. 神经信息处理系统进展 13 (2000). [4] Ondrej Bojar, Rajen Chatterjee, Christian Federmann, Yvette Graham, Barry Haddow, Matthias Huck, Antonio Jimeno Yeps, Philipp Koehn, Varvara Logacheva, Christof Monz, Matteo Negri, Aurelie Neveol, Mariana Neves, Martin Popel, Matt Post, Raphael Rubino, Carolina Scarton, Lucia Specia, Marco Turchi, Karin Verspoor 和 Marcos Zampieri. 2016. 2016年机器翻译会议的发现. 在第一次机器翻译会议的会议记录中. 计算语言学协会, 德国柏林, 131–198. <http://www.aclweb.org/anthology/W/W16/W16-2301> [5] Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell 等. 2020. 语言模型是少量学习者. 神经信息处理系统进展 33 (2020), 1877–1901. [6] Mark Chen, Jerry Tworek, Heewoo Jun, Qiming Yuan, Henrique Ponde de Oliveira Pinto, Jared Kaplan, Harri Edwards, Yuri Burda, Nicholas

约瑟夫, 格雷格·布罗克曼等. 2021年. 评估在代码上训练的大型语言模型. arXiv预印本arXiv:2107.03374 (2021年). [7] 田奇·陈, 邢彪, 张志远, 卡洛斯·古斯特林. 2016年. 以亚线性内存成本训练深度网络. arXiv预印本arXiv:1604.06174 (2016年). [8] 蔡伟霖, 李卓涵, 林子, 盛颖, 吴张浩, 张浩, 郑连敏, 庄思源, 庄永浩, 约瑟夫·E·冈萨雷斯, 伊昂·斯托伊卡, 埃里克·P·辛. 2023年. Vicuna: 一个开源聊天机器人, 以90% * ChatGPT质量给GPT-4留下深刻印象. <https://lmsys.org/blog/2023-03-30-vicuna/> [9] 阿坎克沙·乔杜里, 沙兰·纳朗, 雅各布·德夫林, 马尔滕·博斯马, 戈拉夫·米什拉, 亚当·罗伯茨, 保罗·巴哈姆, 郑亨元, 查尔斯·萨顿, 塞巴斯蒂安·格尔曼等. 2022年. Palm: 通过路径扩展语言建模. arXiv预印本arXiv:2204.02311 (2022年). [10] 丹尼尔·克兰克肖, 古尔·埃亚尔·塞拉, 向熙·莫, 科里·祖马尔, 伊昂·斯托伊卡, 约瑟夫·冈萨雷斯, 阿列克谢·图曼诺夫. 2020年. InferLing: 针对预测服务管道的延迟感知配置和扩展. 在第11届ACM云计算研讨会论文集. 477–491. [11] 丹尼尔·克兰克肖, 王鑫, 朱利奥·周, 迈克尔·J·富兰克林, 约瑟夫·E·冈萨雷斯, 伊昂·斯托伊卡. 2017年. Clipper: 一个低延迟在线预测服务系统. 在第14届USENIX网络系统设计与实现研讨会 (NSDI 17). 613–627. [12] 魏浩·崔, 赵寒, 陈全, 魏浩, 李子瑞, 曾德泽, 李超, 郭敏怡. 2022年. DVABatch: 多入口多出口批处理的多样性感知, 以高效处理GPU上的DNN服务. 在2022年USENIX年度技术会议 (USENIX ATC 22). 183–198. [13] Tri Dao, Dan Fu, Stefano Ermon, Atri Rudra, Christopher Ré. 2022年. Flashattention: 快速且内存高效的精确注意力, 具有IO感知. 神经信息处理系统进展35 (2022年), 16344–16359. [14] 方佳瑞, 余扬, 赵承多, 周杰. 2021年. TurboTransformers: 一个高效的GPU服务系统, 用于变换器模型. 在第26届ACM SIGPLAN并行编程原理与实践研讨会论文集. 389–402. [15] FastAPI. 2023年. FastAPI. <https://github.com/tiangolo/fastapi>. [16] 高品, 余灵凡, 吴永伟, 李金阳. 2018年. 低延迟RNN推理与单元批处理. 在第十三届EuroSys会议论文集. 1–15. [17] 阿米尔·戈拉米, 姚哲伟, 金世勋, 迈克尔·W·马霍尼, 库尔特·库特泽. 2021年. 人工智能与内存墙. RiseLab Medium Post 1 (2021年), 6. [18] Github. 2022年. <https://github.com/features/copilot> [19] 谷歌. 2023年. <https://bard.google.com/> [20] 阿尔潘·古贾拉提, 雷扎·卡里米, 萨菲亚·阿尔扎亚特, 魏浩, 安托万·考夫曼, 伊米尔·维格夫森, 乔纳森·梅斯. 2020年. 像时钟一样服务{DNNs}: 从底层实现性能可预测性. 在第14届USENIX操作系统设计与实现研讨会 (OSDI 20). 443–462. [21] 韩明聪, 张汉泽, 陈荣, 陈海波. 2022年. 微秒级抢占以进行并发{GPU加速}{DNN}推理. 在第16届USENIX操作系统设计与实现研讨会 (OSDI 22). 539–558. [22] 何恺明, 张宇, 任少卿, 孙健. 2016年. 用于图像识别的深度残差学习. 在IEEE计算机视觉与模式识别会议论文集. 770–778. [23] 黄建钦, 顾金, 李金阳. 2020年. Swapadvisor: 通过智能交换将深度学习推向GPU内存限制之外. 在第二十五届国际编程语言和操作系统架构支持会议论文集. 1341–1355. [24] 帕拉斯·贾因, 阿贾伊·贾因, 阿尼鲁德·努鲁西马, 阿米尔·戈拉米, 皮特·阿贝尔, 约瑟夫·冈萨雷斯, 库尔特·库特泽, 伊昂·斯托伊卡. 2020年. Checkmate: 通过最佳张量重物理打破内存墙。

机器学习与系统会议 2 (2020), 497–511. [25] Tom Kilburn, David BG Edwards, Michael J Lanigan, 和 Frank H Sumner. 1962. 单级存储系统. IRE 电子计算机交易 2 (1962), 223–235. [26] Brian Lester, Rami Al-Rfou, 和 Noah Constant. 2021. 参数高效提示调优的规模效应. arXiv 预印本 arXiv:2104.08691 (2021). [27] Xiang Lisa Li 和 Percy Liang. 2021. 前缀调优: 优化生成的连续提示. arXiv 预印本 arXiv:2101.00190 (2021). [28] Zhuohan Li, Lianmin Zheng, Yinmin Zhong, Vincent Liu, Ying Sheng, Xin Jin, Yanping Huang, Zhifeng Chen, Hao Zhang, Joseph E Gonzalez, 等. 2023. AlpaServe: 用于深度学习服务的模型并行统计复用. arXiv 预印本 arXiv:2302.11665 (2023). [29] Lingxiao Ma, Zhiqiang Xie, Zhi Yang, Jilong Xue, Youshan Miao, Wei Cui, Wenxiang Hu, Fan Yang, Lintao Zhang, 和 Lidong Zhou. 2020. Rammer: 通过 rtasks 实现整体深度学习编译器优化. 在第十四届 USENIX 操作系统设计与实现会议论文集中. 881–897. [30] NVIDIA. [n. d.]. Triton 推理服务器. <https://developer.nvidia.com/nvidia-triton-inference-server>. [31] NVIDIA. 2023. FasterTransformer. <https://github.com/NVIDIA/FasterTransformer>. [32] NVIDIA. 2023. NCCL: NVIDIA 集体通信库. <https://developer.nvidia.com/nccl>. [33] Christopher Olston, Noah Fiedel, Kiril Gorovoy, Jeremiah Harmsen, Li Lao, Fan gwei Li, Vinu Rajashekar, Sukriti Ramesh, 和 Jordan Soyke. 2017. Tensorflow-serving: 灵活的高性能机器学习服务. arXiv 预印本 arXiv:1712.06139 (2017). [34] OpenAI. 2020. <https://openai.com/blog/openai-api> [35] OpenAI. 2022. <https://openai.com/blog/chatgpt> [36] OpenAI. 2023. <https://openai.com/blog/custom-instructions-for-chatgpt> [37] OpenAI. 2023. GPT-4 技术报告. arXiv:2303.08774 [cs.CL] [38] LMSYS ORG. 2023. 聊天机器人竞技场排行榜第8周: 介绍 MT-Bench 和 Vicuna-33B. <https://lmsys.org/blog/2023-06-22-leaderboard/>. [39] Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, 等. 2019. Pytorch: 一种命令式风格的高性能深度学习库. 神经信息处理系统进展 32 (2019). [40] Shishir G Patil, Paras Jain, Prabal Dutta, Ion Stoica, 和 Joseph Gonzalez. 2022. POET: 在微型设备上训练神经网络, 集成重材料化和分页. 在国际机器学习会议上. PMLR, 17573–17583. [41] Reiner Pope, Sholto Douglas, Aakanksha Chowdhery, Jacob Devlin, James Bradbury, Anselm Levskaya, Jonathan Heek, Kefan Xiao, Shivani Agrawal, 和 Jeff Dean. 2022. 高效扩展变换器推理. arXiv 预印本 arXiv:2211.05102 (2022). [42] Jie Ren, Samyam Rajbhandari, Reza Yazdani Aminabadi, Olatunji Ruwase, Shuangyan Yang, Minjia Zhang, Dong Li, 和 Yuxiong He. 2021. ZeRO-Offload: 民主化十亿规模模型训练. 在 USENIX 年度技术会议上. 551–564. [43] 路透社. 2023. <https://www.reuters.com/technology/tech-giants-ai-like-bing-bard-poses-billion-dollar-search-problem-2023-02-22/> [44] 亚马逊网络服务. 2023. <https://aws.amazon.com/bedrock/> [45] Haichen Shen, Lequn Chen, Yuchen Jin, Liangyu Zhao, Bingyu Kong, Matthai Philipose, Arvind Krishnamurthy, 和 Ravi Sundaram. 2019. Nexus: 一个加速基于 DNN 的视频分析的 GPU 集群引擎. 在第27届 ACM 操作系统原理研讨会上. 322–337. [46] Ying Sheng, Lianmin Zheng, Binhang Yuan, Zhuohan Li, Max Ryabinin, Daniel Y Fu, Zhiqiang Xie, Beidi Chen, Clark Barrett, Joseph E Gonzalez, 等. 2023. 大规模生成推理的高吞吐量

单GPU的语言模型. arXiv预印本arXiv:2303.06865 (2023). [47] Mohammad Shoeybi, Mostofa Patwary, Raul Puri, Patrick LeGresley, Jared Casper和Bryan Catanzaro. 2019年. Megatron-1m: 使用模型并行性训练数十亿参数的语言模型. arXiv预印本arXiv:1909.08053 (2019). [48] Benoit Steiner, Mostafa Elhoushi, Jacob Kahn和James Hegarty. 2022年. OLLA: 优化数组的生命周期和位置以减少神经网络的内存使用. (2022). <https://doi.org/10.48550/arXiv.2210.12924> [49] Ilya Sutskever, Oriol Vinyals和Quoc V Le. 2014年. 使用神经网络的序列到序列学习. 神经信息处理系统进展27 (2014). [50] Rohan Taori, Ishaan Gulrajani, Tianyi Zhang, Yann Dubois, Xuechen Li, Carlos Guestrin, Percy Liang和Tatsunori B. Hashimoto. 2023年. 斯坦福Alpaca: 一个遵循指令的LLaMA模型. https://github.com/tatsu-lab/stanford_alpaca. [51] ShareGPT团队. 2023年. <https://sharegpt.com/> [52] Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie-Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar等. 2023年. Llama: 开放且高效的基础语言模型. arXiv预印本arXiv:2302.13971 (2023). [53] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser和Illia Polosukhin. 2017年. 注意力是你所需要的一切. 神经信息处理系统进展30 (2017). [54] Jing Wang, Youyou Lu, Qing Wang, Minhui Xie, Keji Huang和Jiwu Shu. 2022年. Pacman: 一种高效的压缩方法, 用于{日志结构}{键值}存储在持久内存上. 在2022年USENIX年度技术会议 (USENIX ATC 22) 上. 773–788. [55] Linnan Wang, Jinmian Ye, Yiyang Zhao, Wei Wu, Ang Li, Shuaiwen Leon Song, Zenglin Xu和Tim Kraska. 2018年. 超级神经元: 用于训练深度神经网络的动态GPU内存管理. 在第23届ACM SIGPLAN并行编程原理与实践研讨会的会议记录中. 41–53. [56] Xiaohui Wang, Ying Xiong, Yang Wei, Mingxuan Wang和Lei Li. 2021年. LightSeq: 一个高性能的推理库, 用于变换器. 在2021年北美计算语言学协会会议的会议记录中: 人类语言技术: 行业论文. 113–120. [57] Yizhong Wang, Yeganeh Kordi, Swaroop Mishra, Alisa Liu, Noah A Smith, Daniel Khashabi和Hannaneh Hajishirzi. 2022年. 自我指导: 将语言模型与自生成的指令对齐. arXiv预印本arXiv:2212.10560 (2022). [58] Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Rémi Louf, Morgan Funtowicz等. 2020年. 变换器: 最先进的自然语言处理. 在2020年自然语言处理经验方法会议的会议记录中: 系统演示. 38–45. [59] Yonghui Wu, Mike Schuster, Zhifeng Chen, Quoc V Le, Mohammad Norouzi, Wolfgang Macherey, Maxim Krikun, Yuan Cao, Qin Gao, Klaus Macherey等. 2016年. 谷歌的神经机器翻译系统: 弥合人类与机器翻译之间的差距. arXiv预印本arXiv:1609.08144 (2016). [60] Gyeong-In Yu, Joo Seong Jeong, Geon-Woo Kim, Soojeong Kim和Byung-Gon Chun. 2022年. Orca: 一个用于{基于变换器}生成模型的分布式服务系统. 在第16届USENIX操作系统设计与实现研讨会 (OSDI 22) 上. 521–538. [61] Hong Zhang, Yupeng Tang, Anurag Khandelwal和Ion Stoica. 2023年. SHEPHERD: 在野外服务DNN. 在第20届USENIX网络系统设计与实现研讨会 (NSDI 23) 上. USENIX协会, 马萨诸塞州波士顿, 787–808. <https://www.usenix.org/conference/nsdi23/presentation/zhang-hong>

[62] 苏珊·张, 斯蒂芬·罗勒, 纳曼·戈亚尔, 米克尔·阿尔特特克, 莫雅·陈, 朔辉·陈, 克里斯托弗·德万, 莫娜·迪亚布, 李贤, 林希·维多利亚, 等。2022年。Opt: 开放的预训练变换器语言模型。arXiv预印本arXiv:2205.01068 (2022年)。[63] 郑连敏, 李卓涵, 张浩, 庄永浩, 陈志峰, 黄艳平, 王怡达, 徐元忠, 卓丹阳,

Eric P Xing 等。2022。Alpa: 自动化分布式深度学习的跨操作员和内部操作员并行性。在第16届USENIX操作系统设计与实现研讨会 (OSDI 22). 559–578. [64] Zhe Zhou, Xuechao Wei, Jiejing Zhang 和 Guangyu Sun. 2022。PetS: 一种用于参数高效变换器服务的统一框架。在2022年USENIX年度技术会议 (USENIX ATC 22). 489–504.